Nama : Ainun Khoirul Umam
NIM : 2395114059

LAPORAN PRAKTIKUM
PERSIAPAN DATASET CITRA DAUN CABAI

1. DESKRIPSI DOMAIN DATASET

Dataset yang digunakan pada praktikum ini berisi citra daun tanaman cabai yang diklasifikasikan ke dalam tiga kelas, yaitu Healthy Leaf (daun sehat), Leaf Curl (daun keriting), dan Spot Leaf (daun bercak). Domain dataset berfokus pada identifikasi kondisi daun cabai berdasarkan gejala visual yang muncul pada permukaan daun. Dataset ini digunakan untuk tujuan klasifikasi citra menggunakan metode pembelajaran mesin, sehingga diperlukan proses persiapan data agar kualitas dan konsistensi data lebih terjaga.

2. DESKRIPSI DATASET

Dataset diperoleh secara lokal dan disimpan dalam folder dataset_raw. Berdasarkan hasil pemeriksaan, setiap kelas berisi 1.000 file gambar dengan format .jpg sehingga jumlah awal seluruh dataset adalah 3.000 gambar. Informasi tambahan seperti perangkat kamera, lokasi dan waktu pengambilan, resolusi asli, serta lisensi dataset tidak tercantum dalam hasil audit yang diberikan, sehingga informasi tersebut tidak diasumsikan dalam laporan ini.

2.1 Statistik Dataset Awal

Tabel 2.1 Statistik Dataset Awal

Kelas	Jumlah Gambar	Format File	Sumber Data
Healthy Leaf	1.000	.jpg	Lokal (dataset_raw)
Leaf Curl	1.000	.jpg	Lokal (dataset_raw)
Spot Leaf	1.000	.jpg	Lokal (dataset_raw)
Total	3.000	.jpg	—

2.2 Hasil Audit Dataset

Dataset diperiksa menggunakan skrip Python untuk memverifikasi file gambar, mendeteksi gambar duplikat berdasarkan hash, dan menghasilkan laporan CSV. Hasil pemeriksaan menunjukkan tidak ditemukan file corrupt. Audit juga menemukan kelompok gambar duplikat lintas kelas yang perlu ditinjau agar satu gambar yang sama atau sangat mirip tidak menimbulkan ketidakkonsistenan label.

Tabel 2.2 Hasil Audit Dataset

Keterangan	Jumlah
Total gambar awal	3.000
Total gambar unik setelah audit	2.159
File corrupt (tidak terbaca)	0

Keterangan	Jumlah
Kelompok duplikat lintas kelas yang ditandai	9
File duplikat dalam kelas yang dikecualikan	817

2.3 Pembagian Dataset

Setelah audit, gambar unik dibagi menjadi data latih (70%), data validasi (15%), dan data uji (15%). Pembagian dilakukan dengan seed 42 agar hasil pembagian dapat direproduksi. Jumlah per kelas berdasarkan keluaran audit adalah sebagai berikut.

Tabel 2.3 Jumlah Dataset Akhir per Kelas

Kelas	Gambar Unik	Data Latih (70%)	Data Validasi (15%)	Data Uji (15%)
Healthy Leaf	564	394	84	86
Leaf Curl	768	537	115	116
Spot Leaf	827	578	124	125
Total	2.159	1.509	323	327

3. PRA-PEMROSESAN DATA

Tahap pra-pemrosesan yang dilakukan dalam audit meliputi pemeriksaan keterbacaan file gambar, identifikasi gambar duplikat, dan penyiapan struktur dataset hasil pembagian. File yang tidak dapat dibaca dicatat pada laporan file_corrupt.csv. Informasi kelompok duplikat lintas kelas dan duplikat dalam kelas disimpan pada laporan CSV terpisah untuk ditinjau.

Folder dataset_raw tetap dipertahankan dan tidak diubah oleh skrip. Hasil pemrosesan disimpan pada folder dataset_bersih, sedangkan rekap dan laporan audit disimpan pada folder hasil_audit. Sebelum pelatihan model, sembilan kelompok duplikat lintas kelas perlu diperiksa secara manual untuk memastikan label kelas yang benar.

4. RENCANA AUGMENTASI CITRA

Augmentasi berikut merupakan rencana untuk tahap pelatihan, bukan klaim bahwa augmentasi telah dijalankan pada audit yang dilaporkan. Augmentasi dapat digunakan untuk menambah variasi data latih dan membantu model menghadapi perubahan visual yang wajar.

Teknik	Rencana Penggunaan
Resize	Menyeragamkan ukuran citra sesuai kebutuhan model yang akan digunakan.
Horizontal flip	Membalik citra secara horizontal jika orientasi tersebut tidak mengubah makna kelas.
Rotasi kecil	Rotasi terbatas, misalnya sekitar ±15 derajat, untuk menambah variasi sudut.
Brightness/contrast	Perubahan ringan untuk mensimulasikan variasi pencahayaan.

Augmentasi hanya diterapkan pada data latih setelah pembagian train/validation/test. Data validasi dan data uji sebaiknya tidak diaugmentasi dengan transformasi acak, sehingga evaluasi dilakukan pada data yang konsisten dan mencegah kebocoran data.

5. POTENSI BIAS VISUAL DAN MITIGASI

Citra daun dapat memiliki perbedaan latar belakang, pencahayaan, sudut pengambilan, dan kondisi lingkungan. Jika suatu kelas lebih sering muncul dengan latar tertentu, model berisiko mempelajari latar belakang sebagai petunjuk kelas (shortcut learning), bukan gejala pada daun. Selain itu, temuan duplikat lintas kelas mengindikasikan adanya kemungkinan ketidakkonsistenan label yang perlu ditinjau.

Mitigasi yang disarankan adalah memeriksa kelompok duplikat lintas kelas, memastikan label sesuai kondisi visual daun, mempertahankan variasi latar dan pencahayaan, serta mengevaluasi performa model pada citra yang berasal dari kondisi berbeda. Langkah-langkah ini merupakan rekomendasi untuk menjaga kualitas dataset.

6. JAWABAN PERTANYAAN FORMATIF

6.1 Mengapa data leakage perlu dicegah?

Data leakage terjadi ketika informasi dari data validasi atau data uji ikut memengaruhi pelatihan. Hal ini dapat membuat hasil evaluasi terlihat lebih baik daripada kemampuan model pada data baru. Pembagian data perlu dilakukan sebelum augmentasi, dan gambar duplikat harus ditinjau agar versi gambar yang sama tidak tersebar di bagian data yang berbeda.

6.2 Apa yang dimaksud shortcut learning?

Shortcut learning adalah kondisi ketika model memanfaatkan petunjuk yang mudah dipelajari tetapi tidak benar-benar mewakili objek utama, misalnya latar belakang atau pola pencahayaan. Untuk mengurangi risiko ini, dataset perlu memiliki variasi visual dan proses evaluasi perlu memeriksa apakah model benar-benar mengenali ciri daun.

6.3 Mengapa pencatatan proses penting?

Pencatatan proses membuat tahapan persiapan data dapat diulang dan diperiksa. Pada audit ini, seed pembagian adalah 42 dan laporan CSV disimpan untuk mencatat rekap dataset, duplikat lintas kelas, duplikat dalam kelas, serta file corrupt.

7. KESIMPULAN

Dataset awal berjumlah 3.000 gambar yang terbagi rata pada tiga kelas. Hasil audit mencatat 0 file corrupt, 9 kelompok duplikat lintas kelas untuk ditinjau, dan 817 file duplikat dalam kelas yang dikecualikan. Dataset akhir yang tercatat berjumlah 2.159 gambar unik dengan pembagian 1.509 data latih, 323 data validasi, dan 327 data uji. Sebelum pelatihan model, kelompok duplikat lintas kelas perlu diverifikasi dan rencana augmentasi harus diterapkan hanya pada data latih.

LAMPIRAN: FILE HASIL AUDIT

Berdasarkan keluaran terminal yang diberikan, skrip menghasilkan file rekap_dataset_bersih.csv, duplikat_lintas_kelas.csv, duplikat_dalam_kelas.csv, dan file_corrupt.csv di folder hasil_audit. File-file tersebut dapat digunakan untuk meninjau hasil audit secara terperinci.